INSTITUTO POLITÉCNICO NACIONAL

Escuela Superior de Cómputo “ESCOM”

Valencia Villanueva Adrian

Resúmenes de Artículos

Índice

1) Sismos: Cuando México tiembla: la historia contada por los datos…… 2

2) Agua: Territorial Information Retrieval from Heterogeneous Open Data… Water Management in Mexico City…… 4

3) Obra pública: A Dimensional Data Warehouse for Geospatial Monitoring of Municipal Public Works……... 6

Sismos

Artículo: Cuando México tiembla: la historia contada por los datos, revista AZCATL (2026).

Problema e importancia

México está en el Cinturón de Fuego del Pacífico y sobre cinco placas tectónicas, así que cerca del 70 % del territorio tiene riesgo sísmico, incluidas zonas muy pobladas como el Valle de México y Guadalajara. Los sismos no se pueden pronosticar con certeza, por lo que importa tener datos confiables de magnitud, profundidad y ubicación. Los datos del Servicio Sismológico Nacional (SSN) son muy técnicos y poco amigables. El sistema propuesto los convierte en visualizaciones accesibles para ciudadanía, educación, gobierno e investigación.

Datos, formato y limpieza

Hay tres fuentes en CSV: El catálogo del SSN (más de 300 000 sismos desde 1900), el Censo de Población y Vivienda 2020 y los Censos Económicos del INEGI. Un detalle que se debe mencionar es, el texto cita los Censos Económicos 2019, pero la referencia dice 2024, pero eso ya es una inconsistencia del propio artículo. Un programa en Python busca campos vacíos, coordenadas inconsistentes y formatos incompatibles. Elimina los registros inválidos y genera un script SQL que se carga en PostgreSQL. No se reporta cuántos registros se descartaron.

Modelado

La información se organiza como *data warehouse* en PostgreSQL. La Figura 6 del artículo muestra cinco tablas: *dim_sismos*, *dim_zonas*, *dim_tiempo*, *dim_economia* y *fact_impacto_sismos_imputed*, es decir, un esquema dimensional con una tabla de hechos de impacto. Encima hay servicios en PHP 8 con Apache, interfaz en HTML5, Bootstrap y JavaScript, y mapas con OpenStreetMap. Todo se despliega con Docker Compose en dos contenedores: *base de datos* y *servidor web*.

Preguntas que responde

- ¿Qué sismos de magnitud ≥ 2 ocurrieron y qué localidades de más de 50 000 habitantes están cerca?

- ¿Qué muestra un reporte por estado, año o periodo? Por ejemplo, Jalisco 2017 tiene 47 sismos, el mayor de magnitud 5.6 y más de 5.4 millones de personas potencialmente afectadas.

- ¿Cómo se distribuyen las magnitudes, qué relación hay entre magnitud y profundidad y cuántos sismos hay por mes?

- ¿Qué alcance tuvo un sismo y qué localidades afectó, mediante mapas de calor?

- Reportes personalizados por periodo, magnitud, localidad, profundidad, habitantes o producción económica.

Limitaciones y trabajo futuro

El sistema describe y visualiza, no predice. No presenta evaluación cuantitativa ni explica qué significa “imputed” ni cómo estima la población afectada. Su instalación puede ser difícil para usuarios no técnicos, lo que se mitiga con Docker. Como trabajo futuro plantea visualizaciones 3D, más fuentes oficiales e integración con plataformas de alerta temprana.

Agua

Artículo: Territorial Information Retrieval from Heterogeneous Open Data through the Construction of a Data Warehouse for Water Management in Mexico City.

Problema e importancia

La Ciudad de México sufre una crisis hídrica por sobreexplotación del acuífero, fugas y crecimiento poblacional. El SACMEX publica datos abiertos de consumo, pero en formatos poco accesibles y sin herramientas de consulta, lo que limita las decisiones basadas en evidencia. El artículo los vuelve consultables para ciudadanía, funcionarios, investigadores y periodistas.

Datos, formato y limpieza

La fuente es el CSV "Consumo Agua (1er Semestre 2019)" del portal de datos abiertos de la CDMX. Tiene 71,102 registros de solo tres bimestres de 2019. Se añade una serie climática de OpenMeteo y mapa base de OpenStreetMap. El ETL tiene cuatro fases: extracción, validación y limpieza, carga a tablas temporales y poblado de dimensiones y hechos con joins internos. Se descartaron 216 registros (0.30 %) con "NA" en las etiquetas territoriales, y quedaron 70,886 filas.

Modelado

Es un esquema en estrella en PostgreSQL con dos hechos: f*act_consumo_agua* (una manzana por periodo de facturación) y *fact_clima*. Tiene tres dimensiones conformadas: *dim_tiempo* (181 registros), *dim_ubicacion* (1,553 pares alcaldía–colonia) y *dim_indice_des* (cuatro niveles de desarrollo). Un mapeo R2RML republica el almacén como grafo RDF Data Cube (unas 760 000 tripletas), validado con las restricciones IC-1, IC-2, IC-3 e IC-11. Las colonias son centroides y la vecindad es proximidad a 1.5 km.

Preguntas que responde

- ¿Cuánto se consume por año, bimestre, alcaldía y colonia? Incluye un mapa coroplético de las 16 alcaldías.

- ¿Qué alcaldías lideran el consumo y cómo cambia según el nivel de desarrollo?

- ¿Qué colonias vecinas consumen más? Se resuelve con una consulta SPARQL.

- ¿Qué colonias son atípicas frente a su alcaldía? Se mide con una puntuación z.

Limitaciones y trabajo futuro

Cubre un solo semestre, así que no permite concluir causalidad con el clima. La detección de anomalías se evaluó con perturbaciones sintéticas (ROC-AUC 0.966 frente a 0.971 de Isolation Forest) y no detecta fugas reales. Usa centroides en lugar de polígonos. Como trabajo futuro propone un "triple store" con endpoint SPARQL público, polígonos oficiales, identificadores alineados con otras fuentes y reevaluación con datos etiquetados de fugas.

Obra pública

Artículo: A Dimensional Data Warehouse for Geospatial Monitoring of Municipal Public Works, with an Evolution Path Toward a Lakehouse Architecture.

Problema e importancia

Los municipios mexicanos suelen gestionar sus obras con hojas de cálculo y sistemas aislados. Eso impide el análisis histórico, la detección temprana de retrasos y la participación ciudadana informada. El artículo propone un almacén dimensional para monitorear obras en Temascaltepec, Estado de México (64,844 habitantes, 55 comunidades). Busca supervisión transparente y auditable sin plataformas empresariales costosas.

Datos, formato y limpieza

Todos los datos son sintéticos. Un generador con semilla (Faker) produce 1,247 obras, 8,934 eventos de auditoría y 29,928 filas mensuales. Los datos se capturan en formularios web hacia una API REST y "triggers" pueblan el almacén, sin ETL externo. La evidencia (fotos JPG/PNG y PDF) se guarda en Cloudflare R2, con sus metadatos en el almacén. Las coordenadas vienen de OpenStreetMap. Al ser datos generados, el artículo no describe una limpieza propiamente dicha.

Modelado

Es un esquema en estrella en PostgreSQL/Supabase con dos hechos y diez dimensiones. Los hechos son *fact_audit_events* (un evento de auditoría) y *fact_work_monthly* (una obra por mes, *snapshot* periódico). Cinco dimensiones son SCD tipo 2 (obra, región, empresa, personal y presupuesto) y conservan la historia. Tres son tipo 1 y dos son tipo 0. Seis vistas SQL cubren retrasos, alertas, trazabilidad, participación, ejecución presupuestal y anomalías. El mapa es un grafo implícito derivado de las llaves foráneas, no una ontología.

Preguntas que responde

- ¿Qué obras van retrasadas y cuántos días?

- ¿Qué eventos generan alertas, como montos altos, obras canceladas o cambios de presupuesto?

- ¿Cuál era el estado o presupuesto de una obra en una fecha pasada?

- ¿Cuánto se ejecutó por fuente de financiamiento?

- ¿Cómo participan los ciudadanos por región?

- ¿Qué obras son anómalas según tres criterios: costo atípico, retraso extremo y avance físico bajo con avance financiero alto?

Limitaciones y trabajo futuro

Todo resultado es sintético y nada se validó con datos reales. La regla de anomalías logra precisión 0.46 y recall 0.35, y Isolation Forest la supera en AUC. Falla en sobreprecio (recall 0.09) y pagos adelantados (0.06). No hay despliegue alojado, la autenticación es ligera y no es un "lakehouse" completo. Como trabajo futuro propone formato de tabla abierta (Iceberg/Parquet) con DuckDB o Trino, visión por computadora sobre las fotos, un vocabulario OWL, el estándar OC4IDS y validación en más municipios.