



INSTITUTO POLITÉCNICO NACIONAL

Escuela Superior de Cómputo “ESCOM”

Valencia Villanueva Adrian

Propuestas de mejora:
Sistema de visualización de sismos

P**ropuestas basadas en el DDL, los datos de muestra, los scripts de carga y el código PHP del repositorio.**

Título	Tipo	Dificultad
Detección de actividad sísmica inusual con Isolation Forest.	IA	Alta
Asignar el territorio por geometría y calcular población expuesta real.	Modelo de datos	Media a alta
Extracción del estado, claves INEGI, integridad referencial y trazabilidad de la carga.	Calidad de datos	Media

Issue #1: [IA] Detección de actividad sísmica inusual con Isolation Forest

Etiquetas: enhancement, machine-learning

Problema

El sistema muestra conteos, mapas y reportes, pero no señala dónde y cuándo la actividad se sale de lo normal. La tabla de hechos ya tiene un *indice_zscore*, pero es una constante precalculada e insertada de forma estática, idéntica para todos los sismos de un estado. No incorpora el tiempo, así que no sirve para detectar rachas. El índice de riesgo de *datos_sismicos.php* divide entre *ln(población + 1)*, por lo que baja cuando la población crece.

Descripción

Un trabajo por lotes en Python (scikit-learn) corre en un contenedor *ml-worker* de Docker Compose.

1. Define el periodo de análisis. El catálogo antiguo parece registrar solo eventos grandes (los primeros 50 sismos de la muestra tienen magnitud 6.4 o más), así que contar sismos por mes entre épocas no es comparable. Se debe fijar una magnitud mínima de completitud por época, o limitar el análisis a los años con registro homogéneo.

2. Agrupa los sismos de *dim_sismos* por celda geográfica (por ejemplo 1°×1°, usando *latitud* y *longitud*) y por mes (*dim_tiempo*). Usar coordenadas evita depender del campo *estado*, que tiene vacíos por fallas de extracción.

3. Calcula por celda-mes: número de sismos, magnitud máxima, magnitud media, profundidad media y energía acumulada.

4. Normaliza contra el historial de la propia celda dentro de la misma época.

5. Puntúa con Isolation Forest y con una referencia simple (z-score robusto con MAD).

6. Muestra una capa «Actividad inusual» con las celdas mejor puntuadas.

No predice sismos si no que prioriza dónde mirar.

Cambios en el modelo de datos

SQL:

-- Verificar antes el volumen real y la distribución por magnitud y año

SELECT count(*) AS total_sismos FROM dim_sismos;

SELECT t.anio, count(*) AS n, min(s.magnitud) AS mag_min

FROM dim_sismos s JOIN dim_tiempo t ON t.id_tiempo = s.id_sismo -- en la muestra id_tiempo = id_sismo

GROUP BY t.anio ORDER BY t.anio;

CREATE TABLE dim_celda (id_celda SERIAL PRIMARY KEY, lat_min NUMERIC, lat_max NUMERIC,

lon_min NUMERIC, lon_max NUMERIC);

CREATE TABLE fact_actividad_celda_mes (

id_celda INT REFERENCES dim_celda, anio INT, mes INT,

n_sismos INT, mag_max NUMERIC, mag_media NUMERIC, prof_media NUMERIC, energia_log NUMERIC,

PRIMARY KEY (id_celda, anio, mes));

CREATE TABLE dim_modelo_ml (id_modelo SERIAL PRIMARY KEY, nombre TEXT, version TEXT, parametros JSONB);

CREATE TABLE fact_anomalia (id_celda INT, anio INT, mes INT,

id_modelo INT REFERENCES dim_modelo_ml, score NUMERIC, es_anomalia BOOLEAN,

PRIMARY KEY (id_celda, anio, mes, id_modelo));

Justificación

Todo se calcula con datos que ya se almacenan en *dim_sismos* y *dim_tiempo*: magnitud, profundidad, coordenadas y fecha de cada sismo. El artículo reporta más de 300 000 sismos en el catálogo del SSN. El número real en la tabla se confirma con la consulta de arriba. No hay etiquetas de anomalías, así que se usa aprendizaje no supervisado. La validación sería con anomalías sintéticas inyectadas en varias semillas y con casos cualitativos conocidos, y siempre se presenta como priorización, no como pronóstico.

Dificultad

Alta: Requiere un contenedor nuevo, preparación de datos, corregir la completitud del catálogo y evaluación.

Issue #2: Asignar el territorio por geometría y calcular población expuesta real

Etiquetas sugeridas: *enhancement*, *database*, *geospatial*

Problema

- ***Población sobrecontada:*** *poblacion_afectada* es la población total del estado para cada sismo. *std.php* suma esa cifra por sismo, así que un mismo estado se cuenta una y otra vez. No depende de la magnitud ni de la distancia.
- ***Estado por referencia, no por geometría:*** El estado de un sismo es el de la localidad de referencia de la SSN, no el que contiene el epicentro. Por ejemplo, un sismo a 727 km al suroeste de Cabo San Lucas se asigna a *BCS*.
- ***Mapa de calor sin datos:*** Los círculos los dibuja JavaScript con *getRadius(magnitud)*, no se calculan en la base.
- ***«Ciudades Pobladas» son estados:*** La capa muestra estados en coordenadas fijas escritas en PHP, no localidades de 50 000 o más habitantes.

Descripción

1. Activar PostGIS y guardar la geometría de cada sismo.

2. Asignar el estado por geometría con *ST_Intersects* en una columna aparte (*cve_entidad_geo*), sin reemplazar la que viene de la referencia. Para epicentros en el mar, guardar el estado más cercano y la distancia a la costa.

3. Cargar municipios y localidades del Censo 2020, con población y coordenadas.

4. Calcular la **población expuesta** como la suma de la población de las localidades dentro de un radio que depende de la magnitud. El radio se define en una tabla de parámetros documentada.

5. Reemplazar *poblacion_afectada* por esa cifra, y dibujar el mapa de calor con ese mismo radio.

Cambios en el modelo de datos

SQL:

```
CREATE EXTENSION IF NOT EXISTS postgis;

ALTER TABLE dim_sismos ADD COLUMN geom geography(Point,4326),
                       ADD COLUMN cve_entidad_geo CHAR(2) REFERENCES dim_entidad,
                       ADD COLUMN dist_costa_km NUMERIC;

UPDATE dim_sismos SET geom = ST_SetSRID(ST_MakePoint(longitud, latitud),4326)::geography;


CREATE TABLE dim_entidad_geom (cve_entidad CHAR(2) PRIMARY KEY REFERENCES dim_entidad,
                               geom geography(MultiPolygon,4326));

CREATE TABLE dim_municipio (cve_entidad CHAR(2) REFERENCES dim_entidad, cve_municipio CHAR(3),
                            nombre TEXT, PRIMARY KEY (cve_entidad, cve_municipio));
```

```
CREATE TABLE dim_localidad (cve_entidad CHAR(2), cve_municipio CHAR(3), cve_localidad CHAR(4),
  nombre TEXT, pobtot INT, geom geography(Point,4326),
  PRIMARY KEY (cve_entidad, cve_municipio, cve_localidad),
  FOREIGN KEY (cve_entidad, cve_municipio) REFERENCES dim_municipio);

-- Índices espaciales (sin ellos ST_DWithin recorre toda la tabla)
CREATE INDEX idx_sismos_geom     ON dim_sismos     USING GIST (geom);
CREATE INDEX idx_localidad_geom  ON dim_localidad  USING GIST (geom);
CREATE INDEX idx_entidad_geom    ON dim_entidad_geom USING GIST (geom);

-- Estado que contiene el epicentro
UPDATE dim_sismos s SET cve_entidad_geo = g.cve_entidad
FROM dim_entidad_geom g WHERE ST_Intersects(g.geom, s.geom);

-- Epicentros en el mar: Estado más cercano y distancia a la costa
UPDATE dim_sismos s SET cve_entidad_geo = n.cve_entidad, dist_costa_km = n.d / 1000
FROM (SELECT DISTINCT ON (s2.id_sismo) s2.id_sismo, g.cve_entidad,
           ST_Distance(g.geom, s2.geom) AS d
     FROM dim_sismos s2 CROSS JOIN dim_entidad_geom g
     WHERE s2.cve_entidad_geo IS NULL
     ORDER BY s2.id_sismo, ST_Distance(g.geom, s2.geom)) n
WHERE s.id_sismo = n.id_sismo;

CREATE TABLE param_radio_exposicion (mag_min NUMERIC, mag_max NUMERIC, radio_km NUMERIC);

CREATE VIEW v_poblacion_expuesta AS
```

```
SELECT s.id_sismo, COALESCE(SUM(l.pobtot),0) AS poblacion_expuesta
FROM dim_sismos s
JOIN param_radio_exposicion p ON s.magnitud >= p.mag_min AND s.magnitud < p.mag_max
LEFT JOIN dim_localidad l ON ST_DWithin(s.geom, l.geom, p.radio_km * 1000)
GROUP BY s.id_sismo;
```

Justificación

Hoy la «población afectada» es una cifra por estado que se repite y se suma, y no puede responder cuántas personas viven cerca de un sismo. Con geometría y localidades se calcula en SQL y se puede verificar. Además el territorio deja de depender de una localidad de referencia y la capa de ciudades deja de ser una lista de estados.

Dificultad

Media a alta: Requiere los datos del censo por localidad, los polígonos de los estados y definir el radio de exposición.

Issue #3: Extracción del estado, claves INEGI, integridad referencial y trazabilidad de la carga

Etiquetas sugeridas: *bug*, *database*, *data-quality*, *etl*

Problema

- ***Sin lógica ETL en el repositorio:*** Los scripts de carga (`03-dim_sismos.sql`, `05-fact_impacto_sismos_imputed.sql`) son `INSERT` estáticos. La limpieza ocurre en un script externo que no está versionado en lo revisado.
- ***Extracción del estado con fallas:*** *dim_sismos.estado* queda como *' '* aunque la referencia termina en la abreviatura del estado. En la muestra son 15 de 50 sismos: 9 *CHIS*, 5 *MICH* y 1 *BC*.
- ***Medidas precalculadas sin fórmula:*** *indice_zscore* y *determinante_de_riesgo* son constantes insertadas sin documentación. En las filas de la muestra revisadas,

poblacion_afectada coincide con la población del estado, *impacto_economico* con su producción bruta y *riesgo_proporcional* con su cociente.

- ***Vínculos por nombre:*** *dim_sismos*, *dim_zonas* y *dim_economia* se relacionan por el nombre del estado, con ortografías distintas («Mexico» frente a «México», «Veracruz» frente a «Veracruz de Ignacio de la Llave»). *dim_economia.entidad* es un número que no corresponde a la clave INEGI.
- ***Sismos que desaparecen:*** En la muestra, 19 de 50 sismos no están en *fact_impacto_sismos_imputed, std.php* y *datos_sismicos.php* usan *JOIN* interno, así que esos sismos no aparecen en los reportes.
- ***Capa de estados incompleta:*** *sismo.php* compara nombres con *strcasecmp*, y se pierden Coahuila, Michoacán y Veracruz (29 de 32 estados).
- ***Unión por id:*** *sismo.php* une *dim_sismos* con *dim_tiempo* por *id_sismo = id_tiempo*, mientras los demás PHP usan *fact.id_tiempo*.
- ***Sin llave primaria:*** El hecho no tiene PK.

Para confirmar el conteo de sismos ausentes en la base completa:

SQL:

```
SELECT count(*) AS sismos_sin_hecho
FROM dim_sismos s LEFT JOIN fact_impacto_sismos_imputed f USING (id_sismo)
WHERE f.id_sismo IS NULL;
```

Descripción

1. Crear un catálogo de entidades con la clave INEGI de dos caracteres, poblado desde *dim_zonas*, y una tabla de abreviaturas de la SSN. Debe incluir *CHIS*, *MICH* y *BC*.

2. Derivar *cve_entidad* desde el final de la referencia con SQL, en vez de depender de un script externo no versionado. Revisar las referencias que queden sin clave.

3. Agregar llave primaria al hecho y declarar la llave foránea de cada sismo a su estado.

4. Reemplazar por una vista las medidas que resultaron derivadas, y documentar la fórmula de *determinante_de_riesgo* e *indice_zscore* antes de conservarlas.

5. Cambiar los *JOIN* de los PHP a *LEFT JOIN*, relacionar estados por clave y no por nombre, y unir *dim_tiempo* por *id_tiempo*.

6. Registrar cada ejecución de carga, los registros descartados con su motivo y qué valores se estimaron.

Cambios en el modelo de datos

SQL:

```
CREATE EXTENSION IF NOT EXISTS unaccent;

-- 1. Catálogo de entidades (poblarlo ANTES de crear las llaves foráneas)
CREATE TABLE dim_entidad (cve_entidad CHAR(2) PRIMARY KEY, nombre TEXT);
INSERT INTO dim_entidad (cve_entidad, nombre)
SELECT lpad(entidad::text, 2, '0'), nom_ent FROM dim_zonas;

ALTER TABLE dim_zonas ADD COLUMN cve_entidad CHAR(2) REFERENCES dim_entidad;
UPDATE dim_zonas SET cve_entidad = lpad(entidad::text, 2, '0');

-- dim_economia: Coincidir sin acentos. Solo Querétaro difiere ('Querétaro de Arteaga' vs 'Queretaro')
ALTER TABLE dim_economia ADD COLUMN cve_entidad CHAR(2) REFERENCES dim_entidad;
UPDATE dim_economia e SET cve_entidad = z.cve_entidad
FROM dim_zonas z WHERE lower(unaccent(e.nombre_entidad)) = lower(unaccent(z.nom_ent));
```

```
UPDATE dim_economia SET cve_entidad = '22' WHERE nombre_entidad = 'Querétaro de Arteaga';


-- 2. Abreviaturas de la SSN
CREATE TABLE dim_entidad_abreviatura (abreviatura TEXT PRIMARY KEY,
  cve_entidad CHAR(2) NOT NULL REFERENCES dim_entidad);


-- Las que el script externo sí extrajo
INSERT INTO dim_entidad_abreviatura (abreviatura, cve_entidad)
SELECT DISTINCT s.estado, z.cve_entidad
FROM dim_sismos s
JOIN dim_zonas z ON lower(unaccent(z.nom_ent)) = lower(unaccent(s.nombre_estado))
WHERE s.estado <> ''
ON CONFLICT DO NOTHING;


-- Las que fallan (vacías en la extracción o con nombre distinto)
INSERT INTO dim_entidad_abreviatura (abreviatura, cve_entidad) VALUES
  ('CHIS','07'), ('MICH','16'), ('BC','02'), ('VER','30')
ON CONFLICT DO NOTHING;


-- 3. Derivar el estado desde la referencia («..., CHIS» -> 'CHIS')
ALTER TABLE dim_sismos ADD COLUMN cve_entidad CHAR(2) REFERENCES dim_entidad;
UPDATE dim_sismos s SET cve_entidad = a.cve_entidad
FROM dim_entidad_abreviatura a
WHERE a.abreviatura = substring(s.referencia_de_localizacion FROM ',\s*([A-Z]+)\s*$');
```

```
-- Referencias que siguen sin clave (agregar su abreviatura al catálogo)
SELECT DISTINCT substring(referencia_de_localizacion FROM ',\s*([A-Z]+)\s*$') AS abreviatura
FROM dim_sismos WHERE cve_entidad IS NULL;

ALTER TABLE fact_impacto_sismos_imputed ADD PRIMARY KEY (id_sismo);

-- 4. Medidas que resultaron derivadas: Vista en lugar de constantes (LEFT JOIN para no perder sismos)
CREATE VIEW v_impacto_sismo AS
SELECT s.id_sismo,
    z.pobtot AS poblacion_afectada,
    e.produccion_bruta_total AS impacto_economico,
    e.produccion_bruta_total / NULLIF(z.pobtot, 0) AS riesgo_proporcional
FROM dim_sismos s
LEFT JOIN dim_zonas z ON z.cve_entidad = s.cve_entidad
LEFT JOIN dim_economia e ON e.cve_entidad = s.cve_entidad;

-- 5. Trazabilidad de la carga
CREATE TABLE dim_fuente (id_fuente SERIAL PRIMARY KEY, nombre TEXT, url TEXT,
                         version TEXT, fecha_descarga DATE, hash_archivo TEXT);
CREATE TABLE etl_ejecucion (id_ejecucion SERIAL PRIMARY KEY, inicio TIMESTAMP, fin TIMESTAMP,
                            registros_leidos INT, registros_cargados INT);
CREATE TABLE etl_descartado (id SERIAL PRIMARY KEY, id_ejecucion INT REFERENCES etl_ejecucion,
                             id_fuente INT REFERENCES dim_fuente, motivo TEXT, fila JSONB);
ALTER TABLE fact_impacto_sismos_imputed
```

ADD COLUMN es_imputado BOOLEAN, ADD COLUMN metodo_estimacion TEXT,

ADD COLUMN id_fuente INT REFERENCES dim_fuente;

Justificación

El estado de cada sismo ya está en su referencia, así que recuperarlo con SQL elimina el script externo como punto de falla y evita que sismos de Chiapas, Michoacán y Baja California desaparezcan de los reportes. Unir las tablas por una clave estable en vez de por texto y registrar qué se descartó permite rastrear cada cifra hasta su fuente. Ninguno de los cambios modifica lo que ve el usuario, pero hacen confiables las cifras de las que dependen el Issue #3 y el módulo de IA.

Dificultad

Media: Son cambios de esquema y de consultas en tres archivos PHP, con una carga de datos única para poblar las claves y las abreviaturas.